AVE üzerinde ses ve görüntü arasındaki zaman kaymasının etkisi

Eren Kahraman
Yıldız Teknik Üniversitesi
YZM5110 Multimodal Learning
Araştırma projesi · 11 Kasım 2026

GitHub deposu
https://github.com/yasarkasa/yzm5110-ave-audio-shifts

Depo bağlantısı planlanan hedeftir. Herkese açık yayımlama onayı bekleniyor.

Özet

Bu çalışma, yayımlanmış A+V-att modelinde ses ile görüntü arasındaki saat kaymasının olay konumlandırmaya etkisini inceler. Ses özellikleri 0, ±1 ve ±2 saniye kaydırılır. Her koşul, aynı sınır bölümleri sıfırlanmış kaydırmasız kontrolle karşılaştırılır. Model ağırlıkları ve özgün etiketler sabittir.

Özgün AVE testindeki 402 klipte iki saniyelik kayma, referansı ortalama 1,89 yüzde puanı düşürdü (%95 güven aralığı [1,06, 2,74]). Tek müdahale olan yerel ses ortalaması, kaydırılmış örneklerde referansa göre 0,83 puan kazandırdı [0,29, 1,35]. Kayma kaybındaki azalma 0,58 puan oldu ve aralığı sıfırı içerdi [-0,04, 1,18]. Sonuçlar, küçük bir ses ön işlemesinin faydasını ve temiz girdideki maliyetini birlikte gösterir.

1 Araştırma sorusu ve kapsam

Araştırma sorusu, ses akışı görüntüye göre öne veya arkaya kaydırıldığında A+V-att'nin özgün olay sınıfını ve zamanını ne ölçüde geri kazanabildiğidir. Saat kayması, çok kipli kanıtın aynı zaman damgasında güvenilir biçimde birleştiği varsayımını sınar.

Katkılar; beş makalenin eleştirel karşılaştırması, yayımlanmış checkpoint'in özgün testte yeniden üretimi, iki yönlü ve eş maskeli kayma protokolü, yerel ses ortalaması ile norm eşlemeli ablasyon ve kaynak video düzeyinde belirsizlik analizidir. Çalışma bir saniyelik hazır özelliklerle, tek checkpoint ve CPU çıkarımıyla sınırlıdır. [1, 6]

2 Literatür araması ve eleştirel sentez

İlk tarama 9 Kasım 2026'da “audio-visual event localization AVE temporal misalignment”, “temporal inconsistent audio-visual event localization” ve “audio-visual event localization AVE cross-temporal alignment” sorgularıyla yapıldı. Yayıncı kayıtları, tam metinler ve yazar depoları kullanıldı. Seçim, AVE bölüm doğruluğunu raporlayan ve farklı bir kipler arası etkileşim mekanizması sunan beş çalışmaya odaklandı. Bu proje odaklı taramanın kapsamlı bir sistematik derleme iddiası yoktur.

Tian vd. aynı saniyedeki sesle görsel bölgeleri ağırlıklandırır. CMAN, ne zaman ve hangi kipe güvenileceğini kapılarla seçer. PSP, eşzamanlı olmayı gerektirmeyen pozitif çiftler arasında özellik taşır. CMBS, karşı kipteki ilgisiz kanıtı bastırır. AVSGN, sınıf metinlerinin ortak anlamından ve zamanlar arası alt graflardan yararlanır. [1-5]

Yayınlardaki ablasyonlar, mekanizmaları kendi sistemleri içinde değerlendirir. CMAN'da sentinel çıkarılması %77,1'i %76,1'e; PSP çıkarılması %77,8'i %73,7'ye; CMBS zaman bastırmasının çıkarılması %79,3'ü %77,93'e indirir. AVSGN ses-görüntü alt grafı çıkarılınca %83,1'den %80,3'e iner. Bunlar yayınlardan alınan değerlerdir. [2-5]

Çalışma	Tam / zayıf denetimli yayın skoru	Ana mekanizma
AVEL 2018	%72,7 / %66,7	Sesle yönlendirilen görsel dikkat
CMAN 2020	%77,1 / %75,7	Uyarlamalı kip ve zaman seçimi
PSP 2021	%77,8 / %73,5	Pozitif bölüm çiftlerinden yayılım
CMBS 2022	%79,3 / %74,2	Zaman ve olay düzeyinde bastırma
AVSGN 2025	%83,1 / %78,8	Metin destekli anlamsal alt graflar

Skorlar arasındaki artış tek bir bileşene bağlanamaz. Kodlayıcılar, eğitim sinyalleri ve uygulama ayrıntıları farklıdır. Örneğin AVSGN, Tian'ın VGG özellikleri yerine CLIP/CLAP kullanır. Projenin yaklaşımı bu sistemleri yeniden eğitmek yerine, tek checkpoint'te kontrollü kaymayı ve sınır kaybını ölçmektir. Ek A, yönergedeki yedi alanı her makale için karşılaştırır.

Zamansal kaydırmanın kendisi yeni bir fikir olarak ileri sürülmez. AV-AND deposunda AVE üzerinde kayma denemeleri vardır. Buradaki katkı, seçilen ağırlıklarda iki yönü, eş sınır maskesini ve eşlenmiş belirsizliği birlikte raporlayan sınırlı bir deneydir. [10]

3 Seçilen yöntemin teknik açıklaması

AVE görevinde her 10 saniyelik klip, birer saniyelik on bölüme ayrılır. Her bölümün hedefi 28 olay sınıfından biri veya arka plandır. Hazır ses vektörü a(t), 128 boyutludur. Görsel özellik V(t), 7 × 7 konumda 512 boyutlu vektör taşır. [1, 6]

A+V-att önce görsel ve işitsel özellikleri doğrusal dönüşüm ve ReLU ile işler. Ses temsili, aynı saniyedeki bütün görsel konumlara yayınlanır. Öğrenilmiş dönüşümler ve tanh, her görsel konumun dikkat skorunu üretir. Konumlar üzerinde softmax ile normalize edilen dikkat, özgün görsel vektörlerin ağırlıklı toplamını verir.

Bu özet görsel dizi ve özgün ses dizisi iki ayrı çift yönlü LSTM'ye girer. Her LSTM'nin yön başına gizli boyutu 128'dir. İki dizinin 256 boyutlu çıktıları birleştirilir. ReLU, 512'den 64'e doğrusal katman, ReLU ve 29 sınıflı çıktı katmanı ardından softmax bölüm olasılıklarını verir. Tahmin en yüksek olasılıklı sınıftır. [6]

Görsel dikkat ve karar

Her saniyede görsel özet, c(t) = toplam_j alpha(t,j) V(t,j) biçimindedir. alpha(t,j), konumlar üzerinde toplamı 1 olan öğrenilmiş ses koşullu ağırlıklardır. Son karar p(y(t) | A,V), iki BiLSTM'nin bütün klipten aldığı bağlama dayanır. Bu yüzden yalnız puanlanan orta saniyelere bakmak, sınırdaki ses kaybının model içindeki etkisini ortadan kaldırmaz.

Ses kayması önce aynı saniyedeki görsel dikkati, ardından ses BiLSTM bağlamını etkileyebilir. Bu bağlantı deneyin hipotezini kurar. Ana ölçüm bu iki etkinin birleşik sonucudur. Dikkat haritaları veya gizli durumlara yönelik nedensel bir ayrıştırma yapılmadı.

Makale tam denetimli sınıflandırmayı çapraz entropiyle açıklar. İncelenen eğitim betiği MultiLabelSoftMarginLoss kullanır. Proje hazır ağırlıklarla yalnız çıkarım yaptığı için bu fark kaydedildi. Aynı kodun yeniden eğitim sonucu, bu rapordaki checkpoint değerlendirmesinden farklı bir yeniden üretim hedefi olur. [1, 6]

Dersle bağlantı

Hafta 3'teki füzyon ve bozuk kip kontrolleri, tek bileşenin eş koşullarda sınanmasına karşılık gelir. Hafta 4'teki zaman birimi, saat kayması ve hizalama tartışması bir saniyelik ofsetleri motive eder. Hafta 5'teki kaynak ailesine göre bölme ilkesi, eğitim/doğrulama ile kaynak video örtüşmesini ayrıca incelemeyi gerektirir. [9]

4 Yeniden üretim hedefi ve uyarlamalar

Hedef, Tian vd.'nin Tablo 1'inde A+V-att için yayımlanan %72,7 bölüm doğruluğunu özgün test bölümünde yeniden üretmektir. Başlangıç beklentisi, aynı hazır özellikler ve checkpoint ile makalenin bir ondalık basamakta verdiği skora yaklaşmaktır. Aynı kaynaklar ve doğrulanmış veri sırası altında belirgin bir fark, veri veya uygulama uyumsuzluğunu araştırmayı gerektirir. [1]

Özgün model kaynağı ve ağırlık SHA-256 özetleri denetlenir. Eski PyTorch pickle'ı yalnız beklenen sınıflar için izin veren yükleyiciyle okunur. Modern ağ kurulduktan sonra bütün checkpoint parametreleri strict=True ile yüklenir. Dört CUDA sıfır gizli durumu, girdi cihazında oluşturulacak şekilde bellekte değiştirilir. Eski Xavier başlatıcısının adı güncellenir. Öğrenilmiş parametreler korunur. [6]

Ölçüm	Doğru bölüm / toplam	Doğruluk
Yayımlanmış A+V-att	Makale Tablo 1	%72,7
Bu proje, maskesiz 0 sn	2.924 / 4.020	%72,7363

Yuvarlanmış yayın değerine fark +0,0363 yüzde puanı. İki değer bir ondalık basamakta %72,7'dir. Bu sonuç yayımlanmış ağırlıkların çıkarım yeniden üretimidir.

Özgün ortam Python 3.6/PyTorch 0.3.0 iken çalışma Python 3.12.14/PyTorch 2.15.0, NumPy 2.5.4 ve h5py 3.16.0 ile macOS arm64 CPU'da yapıldı. Doğruluk çıkarımında 16 kliplik gruplar ve 4 CPU iş parçacığı kullanıldı.

Google Drive ses bağlantısı kota hatası verdiği için aynı beklenen şekil ve boyuttaki LECOO/AVE aynası kullanıldı. Görüntü özellikleri yazarların HDF5 dosyasından, doğru HTTP 206 Content-Range başlığı ve bayt uzunluğu zorunlu tutularak alındı. Ses aynasının özgün dosyayla tam dosya özeti karşılaştırması yapılamadı. Bu sınır bütün sonuçların yorumuna dahildir. [7, 8]

İlk veri denemesinde tamamen sıfır ses döndüren aralık okuması tespit edildi ve o koşu elendi. Sonraki üç kliplik kontrolde özellikler sonlu ve sıfırdan farklıydı, etiketler aynı veri satırından alındı ve model (3,10,29) çıktı verdi. Yayımlanmış tablolarda kullanılan deneyler bu doğrulanmış veri yolundan üretildi.

Kaynak revizyonu

93f843fed72fb17394df76330df958b0c2dbde76

5 Önerilen iyileştirme ve gerekçesi

Doğrulama bölümünde iki saniyelik kaymada eş maskeli kontrole göre net 77 doğru bölüm kaybı görüldü. Sesin kaynak saniyesi ile hedef saniyenin olay varlığı ayrıştığında kayıp yoğunlaştı. Örneğin çan başlangıcından sonraki sesin erken bir arka plan bölümüne gelmesi, modeli olayı erken tahmin etmeye yöneltebilir.

Bu gözlemden sonra, iyileştirme koşusu görülmeden önce tek müdahale seçildi. Her merkez ses vektörü, yarıçapı iki saniye olan pencerenin geçerli komşularıyla harmanlandı. Merkez %50, komşu ortalaması %50 ağırlık taşır. Merkez ortalamaya ikinci kez katılmaz. Yapay sınır boşlukları ortalamaya girmez ve sıfır kalır. Geçerli komşu yoksa merkez korunur. Sıfır merkez vektörü iki kolda da sıfır kalır.

İşlem

N(t), $0 < |s-t| \leq 2$ koşulunu ve geçerli ses maskesini sağlayan komşular olsun. m(t), N(t) içindeki a(s) vektörlerinin ortalamasıdır. Müdahale $b(t) = 0{,}5\ a(t) + 0{,}5\ m(t)$ uygular. Girdi, A+V-att'nin hem görsel dikkat hem ses LSTM yoluna bu biçimde verilir.

Beklenti, kaymış başlangıç veya bitiş yakınındaki komşuların doğru olaya ait bilgiyi hedef saniyeye kısmen taşımasıdır. Yöntem kayma yönünü veya büyüklüğünü tahmin etmez. Yalnız verilen geçerlilik maskesini kullanır. Özgün görüntü ve etiketler sabittir. Doğru hizalanmış örneklerde komşu karışımı geçişi bulanıklaştırabilir.

Norm eşlemeli ablasyon

Ablasyon $u(t) = a(t)\ ||b(t)||_2 / ||a(t)||_2$ uygular. Sesin merkezdeki özellik yönünü koruyup büyüklüğünü müdahaleninkiyle eşler. Bu, komşu özellik yönlerinin katkısını yalnız norm değişiminden ayırmaya yardımcı olur. Ablasyonun norm hedefi de komşulardan geldiği için bu kontrolün kendisi zaman bağlamı kullanır.

Doğrulama tamamlandığında ±2 saniyede ortalama doğruluk referansta %71,56, müdahalede %72,16, ablasyonda %71,27 bulundu. Kaydırmasız doğruluk %73,42'den %73,34'e indi. Yarıçap veya karışım ağırlığı için test üzerinde arama yapılmadı. Bu tek aday ve bütün gözlenen olumsuz sonuçlar kayıt altına alındı.

Yapılandırma ve yöntem dosyası SHA-256 özetleri testten önce doğrulama çıktısına yazıldı. Test betiği bu özetler uyuşmazsa durur. Böylece aşağıdaki test sonuçları aynı müdahalenin değerlendirmesidir.

6 Deney tasarımı ve ölçüler

Bileşen	Sabitlenen protokol
Veri bölümleri	3.339 eğitim / 402 doğrulama / 402 özgün test
Girdiler ve hedef	10 × 128 ses, 10 × 7 × 7 × 512 görüntü; 29 sınıflı özgün etiket
Ofsetler	-2, -1, 0, +1, +2 saniye; pozitif ofset sesi geciktirir
Sınırlar	Taşıma yok; boş ses sıfır; eş kontrolde aynı sınır sıfır
Puanlama	Her yöntemde ve koşulda 2-7 indisleri, 2.412 bölüm
Belirsizlik	10.000 kaynak video bootstrap tekrarı, seed 2026
Gecikme	CPU 4 iş parçacığı; tek klip; 5 ısınma; her ofsette ilk 32 klip

Ofset k için kaydırılmış ses a_k(t) = a(t-k) olur. Klip dışına çıkan kaynaklar sıfırdır. Örneğin +2'de ilk iki ses bölümü sıfırlanır. Kontrolde ses kaydırılmaz ve aynı ilk iki bölüm sıfırlanır. -2'de son iki bölüm iki kolda da sıfırdır. Klip uçları birbirine sarılmaz. BiLSTM bütün klibi gördüğü için bu eşleme çıkarımdan önce uygulanır.

Birincil kayma ölçüsü D_2, ±2 yönlerinin eş maskeli kontrol eksi kaydırılmış doğruluk farkının ortalamasıdır. Beklenti $D_2 > 0$. İkincil beklenti $D_2 > D_1$'dir. Müdahale için birincil karşılaştırma ±2 kaydırılmış doğrulukta yerel ortalama eksi referans farkıdır. Aynı fark ablasyona karşı da ölçülür. Kaydırmasız maliyet ve yöntem başına D_2 ayrıca raporlanır.

Bootstrap, kaynak video kimliklerini bütün yöntem ve ofsetlerle birlikte yeniden örnekler. Yüzdelik %2,5 ve %97,5 sınırları %95 aralığı verir. Mutlak skor aralıkları ile eşlenmiş fark aralıkları ayrı hesaplanır. Ofset bazındaki aralıklar çoklu karşılaştırma düzeltmesi içermez. Testteki 402 klibin kaynak kimlikleri farklıdır. Eğitim/doğrulamayla ortak sekiz kimlik çıkarılarak 394 klipte duyarlılık analizi yapılır.

Gecikme, bellekteki özelliklerden ön işleme, model ve argmax sonuna kadar ölçülür. Disk/ağ erişimi ve ham kiplerden özellik çıkarımı bu süreye dahil değildir. Yöntem çağrı sırası klipler arasında döndürülür. Zamanlama başına 160 gözlemden medyan ve p95 raporlanır.

7 Sonuçlar ve eşlenmiş kontroller

Kaydırılmış bölüm doğruluğu

Kayma	A+V-att	Yerel ortalama	Norm eşlemeli
-2 sn	%69,98 [66,50, 73,51]	%70,81 [67,33, 74,34]	%70,40 [66,87, 73,88]
-1 sn	%72,64 [69,15, 76,12]	%72,72 [69,24, 76,20]	%72,47 [68,99, 75,91]
+0 sn	%72,60 [69,07, 76,08]	%72,51 [68,95, 76,04]	%72,39 [68,91, 75,83]
+1 sn	%71,52 [67,99, 74,96]	%72,10 [68,53, 75,58]	%71,43 [67,91, 74,88]
+2 sn	%69,40 [65,88, 72,93]	%70,23 [66,67, 73,80]	%69,53 [66,00, 73,05]

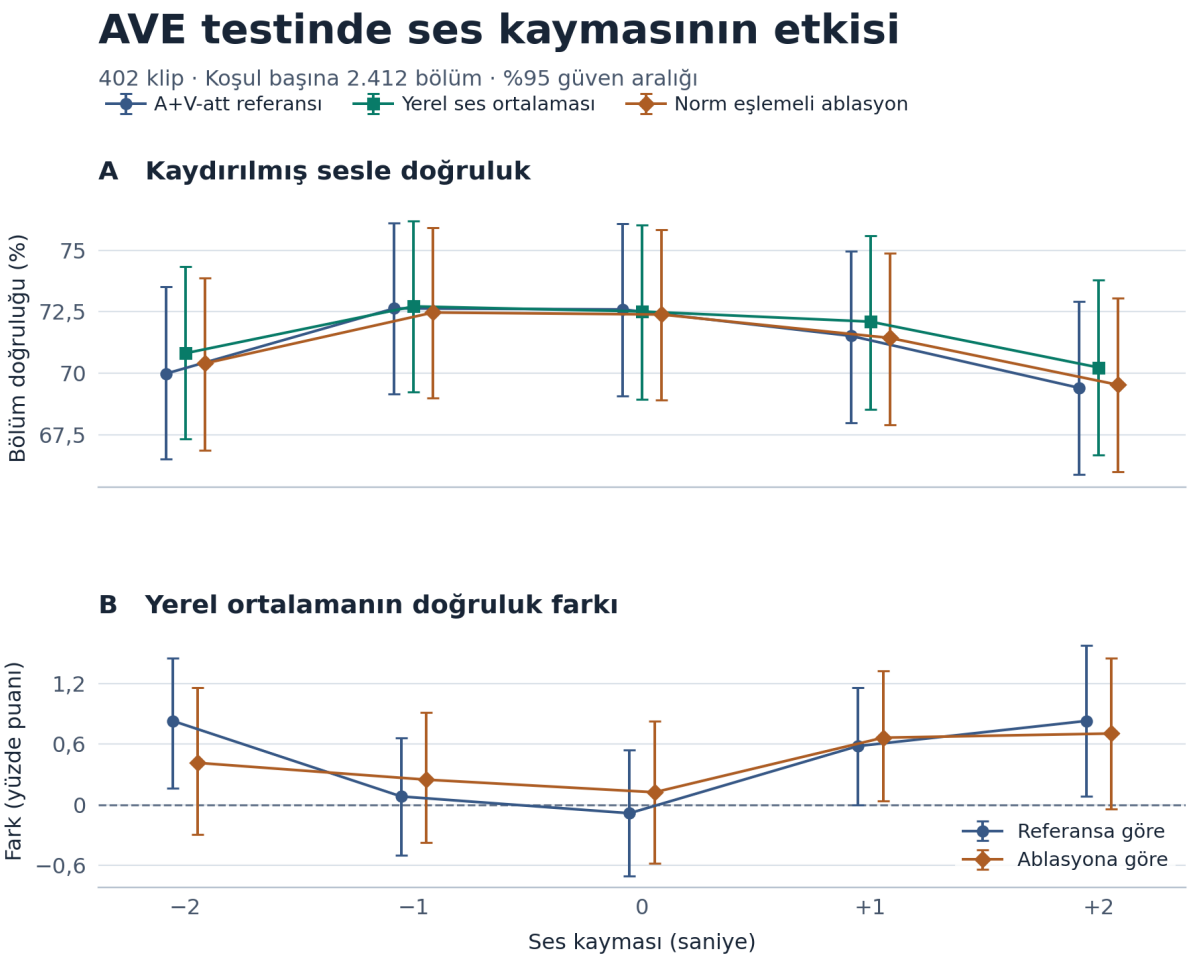
İki yönün ortalamasında kayma kaybı

Yöntem	D_1 (yüzde puanı)	D_2 (yüzde puanı)
A+V-att	0,39 [-0,19, 0,97]	1,89 [1,06, 2,74]
Yerel ortalama	0,02 [-0,46, 0,52]	1,31 [0,56, 2,07]
Norm eşlemeli	0,44 [-0,15, 1,02]	1,47 [0,64, 2,30]

Referansın D_2 aralığı sıfırın üstünde olduğu için birincil kayma hipotezi desteklenir. D_2 - D_1 farkı 1,49 [0,68, 2,34] yüzde puanıdır. Bir saniyelik kaymada toplam yön ortalaması belirsizken iki saniyede düşüş daha belirgindir. İleri ve geri yönün büyüklüğü aynı değildir.

Yerel ortalama ±2 saniyede ortalama %70,52, referans %69,69 ve ablasyon %69,96 verdi. Müdahale referansı 0,83 [0,29, 1,35], ablasyonu 0,56 [0,02, 1,10] yüzde puanı geçti. Ablasyon farkının alt sınırı sıfıra yakındır. Referansa göre kayma kaybındaki azalma 0,58 [-0,04, 1,18] puandır. Kaydırılmış doğruluk kazanımı, kayma kaybının azaldığı iddiasından daha kesin görünmektedir.

7 Sonuçlar için doğruluk grafiği



Aralıklar kaynak video düzeyinde 10.000 eşlenmiş bootstrap örneğinden hesaplandı.

Şekil 1. Üst panel kaydırılmış örneklerin bölüm doğruluğunu, alt panel yerel ortalama ile iki karşılaştırmanın eşlenmiş farklarını gösterir. Çubuklar kaynak video düzeyinde %95 bootstrap güven aralıklarıdır.

Sınır maskesinin etkisi

Kaymanın kontrolü	A+V-att (%)	Yerel ortalama (%)	Norm eşlemeli (%)
-2 sn	71,27	71,81	71,06
-1 sn	72,26	72,55	72,31
+0 sn	72,60	72,51	72,39
+1 sn	72,68	72,31	72,47
+2 sn	71,89	71,85	71,81

Her kaymanın kontrolü farklı sınırı maskelediği için ayrı bir skor üretir. Örneğin +2 referansı kendi %71,89 kontrolüyle, -2 referansı kendi %71,27 kontrolüyle karşılaştırılır. Tablonun 0 saniyesi %72,60'tır ve altı saniyelik puanlamaya aittir. Makaleyle karşılaştırılan tam klip skoru %72,7363'tür.

7 Kaynak ölçümü ve hata analizi

Yöntem	Medyan ms/klip	p95 ms/klip	Çağrı
A+V-att	0,696	0,757	160
Yerel ortalama	0,717	0,787	160
Norm eşlemeli	0,723	0,795	160

Yerel ortalama medyana yaklaşık 0,020 ms/klip, yani %2,9 ekledi. Bu değer kısa CPU çağrılarının ölçümüdür ve makine yükünden etkilenebilir.

İki saniyelik kaymada olay varlığının hedef ve kaynak saniyeler arasında ayrıştığı 508 bölüm, 4.824 bölüm koşulunun %10,5'idir. Referansın eş maskeli kontrollere göre net 91 kaybının 76'sı (%83,5) bu gruptadır. Bu gruplama özgün zaman etiketlerine dayanır.

Yerel ortalama iki yönde 86 hatayı düzeltti ve 46 yeni hata yaptı. Ayrışan olay varlığı grubunda bu sayılar 21 ve 8'dir. 0 saniyede 27 hata düzeldi ve 29 doğru bölüm bozuldu. Yöntemin temiz girdi üzerindeki ortalama farkı -0,08 [-0,70, 0,54] puandır.

Örnek	Hedef ve referans	Yerel ortalama
Satır 27, +2 sn, t=5. Çan 5-10 sn. Kaynak ses t=3.	Hedef çan. Referans arka plan.	Çan. Başlangıç geri kazanıldı.
Satır 421, +2 sn, t=2. Havlama 1-10 sn. Kaynak ses t=0.	Hedef havlama. Referans havlama.	Arka plan. Yeni kaçırma.
Satır 68, 0 sn, t=6. Çan 6-10 sn.	Hedef çan. Referans çan.	Arka plan. Temiz başlangıç bulanıklaştı.

Eğitim veya doğrulamayla kaynak kimliği ortak sekiz klip çıkarıldığında 394 klip kalır. Referans D_2 = 1,92 [1,10, 2,81] puandır. Müdahalenin referansa kazancı 0,85 [0,32, 1,40], ablasyona kazancı 0,57 [0,02, 1,12] puandır. D_2 azalması 0,59 [-0,04, 1,23] puanla belirsizliğini korur. Ana yorum bu filtreye duyarlı görünmemektedir.

8 Sınırlılıklar ve sonuç

Özgün AVE testinde iki saniyelik ses kayması, A+V-att'nin özgün olayları geri kazanma başarısını düşürdü. Aynı sınır maskesiyle hesaplanan D_2'nin aralığı sıfırın üstünde. Yerel ses ortalaması, küçük bir gecikme maliyetiyle kaydırılmış doğruluğu artırdı. Kayma kaybını azalttığına ilişkin aralık ise sıfırı içeriyor.

Etiketler özgün zaman çizgisinde sabit tutuldu. Bu kurgu, sensör saat hatası altında özgün olayın geri kazanılmasını sınar. Yapay kaymadan sonra “aynı anda duyulan ve görülen olay” tanımına göre yeni etiket üretmek farklı bir değerlendirme kurar. Sonuçların kapsamı bu hedef seçimine bağlıdır.

Tek checkpoint ve tek veri kümesi kullanıldı. Bir saniyelik hazır özellikler, alt saniyelik kaymayı ve ham kodlayıcının davranışını örter. Sentetik sıfır dolgu ve geçerlilik maskesi deney kurulumu tarafından bilinir. Sonuçlar doğal sensör gecikmelerinin bütün çeşitlerini kapsamaz. Yöntem çevrimdışıdır, komşular gelecek saniyeleri ve referans çift yönlü bağlamı kullanır.

Ses aynası özgün dosyayla tam olarak karşılaştırılamadı. Kaynak video örtüşmesi ayrıca sınandı, ön eğitim kaynaklarıyla olası örtüşme ölçülmedi. Bootstrap aralıkları test örneklemesine ilişkindir. Yeniden eğitim veya checkpoint değişkenliğini kapsamaz. Gecikme yalnız hazır özelliklerden CPU çıkarımını kapsar.

Açık sorular, alt saniyelik veya değişken gecikme, doğal uyumsuzluk, farklı checkpoint'ler ve komşu harmanının olay sınırlarını koruyan sürümleridir. Bunlar yeni doğrulama tasarımı gerektirir. Bu rapordaki nihai test sonuçlarıyla ayar değiştirilmedi.

Yapay zekâ kullanımı beyanı

OpenAI Codex; kaynak arama, karşılaştırma matrisi ve sentez taslağı, yazar kodunun CPU uyarlaması, veri doğrulama, deney betikleri, yerel deney yürütme, bootstrap ve hata analizi, grafikler ve rapor/sunum düzenlemesinde kullanıldı. Konu, hipotez, eş maskeli karşılaştırma ve yerel ortalama/ablasyon tasarımı görüşme içinde Codex önerileriyle geliştirildi. Sayısal sonuçlar yerel betik çıktılarından alındı.

Ödev yönergesinin 7. bölümü beyan edilen desteğe izin verir. Kaynakları okuma, uygulamayı anlama, deney tasarımını değerlendirme, iddiaları ve atıfları doğrulama, sonuçları savunma sorumluluğu Eren Kahraman'a aittir. Somut katkılar depodaki AI_USAGE.md içinde açıklanır.

Ek A Beş makalenin karşılaştırma matrisi

A1 Soru ve katkı, kipler ve varsayımlar, mekanizma ve amaç. T/Z, tam ve zayıf denetimli eğitimi gösterir. Yayın sonuçları bu projenin ölçümlerinden ayrıdır.

Makale	Soru ve katkı	Kipler ve varsayımlar	Mekanizma ve amaç
Tian vd. 2018 AVEL	Hem duyulan hem görülen olayın sınıfı ve zamanı bulunabilir mi? AVE görevlerini, veri kümesini ve ses yönlendirmeli görsel dikkati sunar.	Ses ve RGB video. Tam denetimde bölüm, zayıf denetimde klip etiketleri. Hazır VGG-19 ve AudioSet ses özellikleri. Çıkarımda iki kip birlikte verilir.	A+V-att, sesle görsel bölgeleri ağırlıklandırır ve iki BiLSTM çıktısını birleştirir. Makale çapraz entropi tarif eder. İncelenen eğitim betiği MultiLabelSoftMarginLoss kullanır.
Xuan vd. 2020 CMAN	Zamansal uyumsuzlukta konum, zaman ve kip seçimi nasıl yapılır? Uzamsal dikkat, self-attention ve uyarlamalı co-attention ile kanıt seçer.	Ses ve RGB. T/Z eğitim. Ses ile görüntüdeki olay ilişkileri farklı saniyelere yayılabilir. Makale görsel kodlayıcıyı ResNet-151 olarak bildirir.	LSTM sentinel kapısı, kendi kipindeki bellek ile karşı kipten gelen bağlamı ağırlıklandırır. Üç dikkat düzeyi ortak konumlandırma amacına bağlanır.
Zhou vd. 2021 PSP	Aynı olayın farklı saniyelerdeki yararlı ses-görüntü çiftlerinden bilgi taşınabilir mi? Güçlü pozitif bağlantılar üzerinden özellik yayar.	Ses ve RGB, T/Z eğitim. İlişkili çiftlerin aynı zaman indisinde olması gerekmez. VGG-19 ve VGG benzeri ses özellikleri kullanılır.	BiLSTM sonrasında bütün ses-görüntü çiftlerinin benzerliği hesaplanır. Zayıf bağlantılar elenir. Tam denetimde sınıflandırmaya çift benzerliği kaybı eklenir.
Xia ve Zhao 2022 CMBS	Karşı kipteki ilgisiz zaman ve olay kanıtı bastırılınca konumlandırma iyileşir mi? Zaman ve olay düzeyinde arka plan bastırır.	Ses ve RGB, T/Z eğitim. Tek kipteki olay ortak ses-görüntü olayı açısından arka plan olabilir. VGG-19 ve Res-151 görsel seçenekleri ayrılır.	Karşı kipten zaman kapısı ve olay skoru üretir. Olay sınıflandırması ve kapı gözetimi, ilgisiz karşı kip kanıtını bastırır.
Liu vd. 2025 AVSGN	Sınıf metinleriyle ortak anlam ve zamanlar arası etkileşim kurulabilir mi? Üç kipin alt graflarıyla anlamsal ilişkiler taşır.	Ses, RGB ve bilinen sınıf metinleri. Metin klibe özgü transkript değildir. CLIP Swin-V2-L ve CLAP HTS-AT özellikleri kullanılır.	CMSA ile ortak uzay ve CMGI ile ses-görüntü, ses-metin, görüntü-metin alt grafları. Sınıflandırma, olay ilgisi, kapı ve anlamsal tutarlılık kayıpları.

Ek A Veri, kanıt ve yeniden üretim

A2 Aynı beş satırın devamı. Böylece her çalışma yönergedeki yedi değerlendirme alanını kapsar. Tam metin kaynakları [1-5].

Makale	Veri ve protokol	Referans ve kanıt	Kaynak ve yeniden üretim	Sınırlılıklar ve bağlantılar
Tian vd. 2018 AVEL	AVE, 4.143 klip ve 28 olay sınıfı. Özgün bölüm sayıları 3.339/402/402. On adet bir saniyelik bölüm ve arka plan sınıfı.	Tablo 1 A+V-att T/Z %72,7/%66,7. Yalnız ses %59,5, yalnız görüntü %55,3, dikkatsiz A+V %71,4. DMRN ayrı füzyon modeli.	Kod, ağırlıklar ve hazır özellikler mevcut. Python 3.6/PyTorch 0.3.0. Bu proje yayımlanmış ağırlıkları sabit revizyonda CPU'ya uyarlar.	A+V-att referans hedefidir. Özgün etiketleri koruyan kontrollü kayma, saat kayması altında olay geri kazanımını sınar. Yeniden eğitim sonuçları bu projede üretilmedi.
Xuan vd. 2020 CMAN	AVE, %80/%10/%10 bölme. Her saniyede 16 RGB kare. VGG benzeri ses ve makalede bildirilen ResNet görsel özellikleri.	Tablo 1 T/Z %77,1/%75,7. Dikkat modülleri kapalı %71,4/%69,0. Sentinel çıkarılınca Tablo 2 %76,1/%74,9.	Mimari ve ön işleme açıklanır. Resmî kod, yayımlanmış checkpoint ve donanım ayrıntıları ilk taramada doğrulanamadı.	Doğal uyumsuzluğu inceler. Ana tablolar sabit ofset büyüklüğüne ayrılmamıştır. Kapı ablasyonu kip seçim etkisi için örnek sağlar.
Zhou vd. 2021 PSP	AVE bölüm doğruluğu. Depoda HDF5 bölüm listeleri ve etiketler bulunur. Aynı veri kümesi, bütün çalışmaların birebir aynı protokolü kullandığını garanti etmez.	Tablo 1 T/Z %77,8/%73,5. PSP çıkarıldığında %73,7/%70,2. Bütün bağlantıları tutan varyant tam denetimde %75,9.	PyTorch kodu, özellik ve checkpoint bağlantıları var. README tam denetim eşiği 0,099. Makale Tablo 3'teki en iyi eşik 0,095.	Zamanlar arası pozitif çift seçimi projenin motivasyonuna yakın. Eşik ve çift kaybının kontrollü kayma altındaki etkisi ayrıca sınanmalıdır.
Xia ve Zhao 2022 CMBS	AVE bölüm doğruluğu. Ses özellikleri sabit. Görsel kodlayıcı karşılaştırmalarında VGG-19 ve Res-151 ayrı raporlanır.	VGG-19 T/Z %79,3/%74,2. Zaman bastırması çıkarılınca %77,93/%73,45. Olay bastırması çıkarılınca %78,30/%73,57.	Kod, yapılandırma, özellik ve checkpoint bağlantıları mevcut. Depo Python 3.7.6, PyTorch 1.10.2, CUDA 11.4 bildirir.	Arka plan bastırma ile saat kaymasını telafi etme farklı mekanizmalardır. Gecikmiş ama ilgili sesin bastırılması olası hata olarak incelenebilir.
Liu vd. 2025 AVSGN	AVE T/Z bölüm doğruluğu. CLIP ve CLAP ile 512 boyutlu özellikler. Tian'ın VGG tabanlı kodlayıcılarından farklıdır.	Tablo 1 T/Z %83,1/%78,8. Ses-görüntü alt grafı çıkarılınca %80,3/%75,9. Üç alt graf çıkarılınca %79,6/%74,8.	PyTorch, RTX 2080 Ti, 200 epoch ve Adam ayrıntıları verilir. Resmî kod ve modele özgü checkpoint ilk taramada doğrulanamadı.	Yayınlar arası skor farkı kodlayıcı değişimini de içerir. Grafın katkısını aynı sistemin alt graf ablasyonuyla değerlendirmek daha yakındır.

Kaynakça ve yeniden üretim kaydı

[1] Tian, Y., Shi, J., Li, B., Duan, Z. ve Xu, C. (2018). Audio-Visual Event Localization in Unconstrained Videos. ECCV. Kaynak bağlantısı

[2] Xuan, H., Zhang, Z., Chen, S., Yang, J. ve Yan, Y. (2020). Cross-Modal Attention Network for Temporal Inconsistent Audio-Visual Event Localization. AAAI. Kaynak bağlantısı

[3] Zhou, J., Zheng, L., Zhong, Y., Hao, S. ve Wang, M. (2021). Positive Sample Propagation Along the Audio-Visual Event Line. CVPR. Kaynak bağlantısı

[4] Xia ve Zhao (2022). Cross-Modal Background Suppression for Audio-Visual Event Localization. CVPR. Kaynak bağlantısı

[5] Liu vd. (2025). Audio-Visual Semantic Graph Network for Audio-Visual Event Localization. CVPR. Kaynak bağlantısı

[6] Tian vd. AVE-ECCV18 kaynak kodu ve checkpoint. Sabit revizyon 93f843fed72fb17394df76330df958b0c2dbde76. Kaynak bağlantısı

[7] AVE yazarlarının ses ve görüntü özellik bağlantıları. Kaynak bağlantısı

[8] LECOO/AVE ses özelliği aynası. Erişim 10 Kasım 2026. Kaynak bağlantısı

[9] Çetinkaya, E. YZM5110 Multimodal Learning, Hafta 1-5 slaytları ve Research Project yönergesi. 2026. Kullanıcı tarafından sağlanan ders materyalleri.

[10] AV-AND deposu. Kontrollü temporal misalignment örnekleri. Kaynak bağlantısı

Çalıştırılabilir kayıt

Kod, yapılandırma, JSON/CSV çıktıları, komutlar ve yapay zekâ beyanı teslim deposunda yer alır. Yerel teslim adayı submission-v1-rc1, yayımlanacak sürüm submission-v1 etiketiyle tanımlanır. Kod ve deneyler için README.md içindeki sıralı komutlar, tablolar için scripts/export_tables.py ve grafik için scripts/plot_ave_test.py kullanılır.

9-10 Kasım deneyleri 11 Kasım'da teslim için paketlendi. Deneyler sırasında ayrı commit'ler oluşturulmadı. Araştırma planı aşama kayıtlarını korur. Yazar kodu, ders PDF'leri ve veri/özellik dosyaları depoda yeniden dağıtılmaz.

Yapılandırma SHA-256

5adb3bbca7243ed4d56d9ab1488811b6
9b522e6bb8b12246a24f08a568d8b846